

EXECUTIVE SUMMARY

Bank Marketing - Term Deposit Subscription Prediction

Fajar Dwiharjo

24130500010

1. Latar Belakang

Analisis ini memprediksi apakah nasabah akan berlangganan term deposit berdasarkan informasi yang tersedia sebelum kontak telemarketing dilakukan. Tujuan praktisnya adalah membantu tim marketing/call-center memprioritaskan daftar kontak ketika waktu dan kapasitas agen terbatas. Masalah dirumuskan sebagai binary classification dengan target $y = \text{yes/no}$. Karena target tidak seimbang, dengan sekitar 88,3% no dan 11,7% yes, F1-score kelas positif dipilih sejak awal sebagai metrik utama.

2. Dataset (Overview)

- Sumber: UCI Machine Learning Repository, dataset Bank Marketing, file bank-full.csv.
- Ukuran: 45.211 baris dan 17 kolom, terdiri dari 16 input features dan 1 target.
- Fitur mencakup karakteristik nasabah (age, job, marital, education, balance, loan, housing), informasi kampanye sebelumnya (pdays, previous, poutcome), serta informasi kontak (contact, day, month).
- Tidak terdapat NaN dan tidak ditemukan duplicate row. Nilai "unknown" dipertahankan sebagai kategori karena dapat membawa informasi, bukan dihapus sebagai missing value.
- Distribusi target: 39.922 no (88,3%) dan 5.289 yes (11,7%), sehingga accuracy saja tidak cukup untuk menilai model.

3. Metode: Feature Engineering & Pipeline Design

- Feature engineering menghasilkan previously_contacted dari pdays, month_sin/month_cos untuk merepresentasikan sifat siklik bulan, dan balance_log dengan transformasi log yang mempertahankan tanda.
- duration dan campaign dikeluarkan dari primary model. duration baru diketahui saat/setelah panggilan, sedangkan campaign mencakup kontak saat ini, sehingga keduanya berpotensi menyebabkan leakage pada skenario pre-contact.
- Pipeline menggunakan ColumnTransformer: fitur numerik diproses dengan median imputation dan StandardScaler; fitur kategorikal menggunakan most-frequent imputation dan OneHotEncoder(handle_unknown='ignore'). Seluruh preprocessing berada di Pipeline sehingga fitting preprocessing hanya menggunakan data training.
- Data dibagi secara stratified 80:20: 36.168 data training dan 9.043 data test. Perbandingan model menggunakan 5-fold Stratified Cross-Validation pada training set; test set digunakan sekali untuk evaluasi akhir.

4. Perbandingan Model dan Alasannya

Model perbandingan dipilih untuk memberikan baseline sederhana sekaligus melihat perbedaan antara pendekatan linear dan ensemble berbasis tree. Majority-class baseline digunakan sebagai sanity check; Logistic Regression sebagai model linear yang mudah diinterpretasikan; Logistic Regression (balanced) untuk menguji class weighting; sedangkan Random Forest dan HistGradientBoosting digunakan untuk menangkap hubungan non-linear dan interaksi fitur.

Model	F1 CV	F1 Test	Accuracy Test	Recall Test
Random Forest	0.4643	0.4654	0.8514	0.5529
Logistic Regression (balanced)	0.3735	0.3785	0.7563	0.6342
HistGradientBoosting	0.3374	0.3516	0.8952	0.2429
Logistic Regression	0.2757	0.2821	0.8931	0.1796
Baseline	0.0000	0.0000	0.8830	0.0000

Hasil menunjukkan Random Forest memiliki F1 cross-validated tertinggi (0,4643) dan juga F1 test tertinggi (0,4654). HistGradientBoosting memiliki accuracy dan ROC-AUC test lebih tinggi (0,8952 dan 0,8053), tetapi recall positifnya hanya 0,2429 sehingga F1 lebih rendah. Baseline memiliki accuracy 0,8830 tetapi F1 = 0, memperlihatkan mengapa accuracy tidak layak dijadikan dasar utama pada target yang imbalanced.

5. Decision: Model Utama

Random Forest dipilih sebagai model utama karena memperoleh F1 positif tertinggi pada 5-fold cross-validation dan mempertahankan hasil terbaik pada held-out test set. Model yang digunakan adalah RandomForestClassifier dengan 300 trees, max_depth=12, class_weight='balanced', random_state=42. Threshold yang diuji melalui out-of-fold training predictions menghasilkan threshold 0,5 sebagai nilai dengan F1 CV maksimum, sehingga tidak ada perubahan threshold pada evaluasi akhir.

6. Rekomendasi Penggunaan Model

- Gunakan Random Forest untuk prioritasasi kontak berdasarkan probabilitas subscription, bukan sebagai keputusan otomatis bahwa nasabah pasti akan berlangganan.
- Pertahankan aturan pre-contact dan jangan memasukkan duration atau campaign pada deployment yang memiliki timing sama dengan studi.
- Untuk pengembangan berikutnya, lakukan tuning hyperparameter secara lebih formal, bandingkan SMOTE/oversampling di dalam training folds, gunakan data kampanye yang lebih baru, dan masukkan biaya false positive/false negative agar threshold dapat dipilih berdasarkan business cost.

7. Limitasi Model

- Data bersifat historis dan observasional dari satu bank di Portugal, sehingga generalisasi ke bank, negara, populasi, atau periode lain belum terjamin.
- Perubahan perilaku nasabah, kondisi ekonomi, dan proses marketing dapat menyebabkan performance drift; validasi ulang dengan data terbaru diperlukan.
- Class imbalance membatasi peningkatan recall tanpa konsekuensi false positive yang lebih besar.
- Tidak tersedia biaya finansial aktual untuk false positive dan false negative, sehingga manfaat bisnis belum dapat dihitung secara kuantitatif.
- Model menunjukkan association, bukan causation. Evaluasi menggunakan satu stratified train/test split dan 5-fold CV, sehingga metrik test merupakan point estimate, bukan estimasi variasi populasi yang sepenuhnya bebas bias.
- Diagnostic dengan duration menunjukkan performa yang tampak lebih kuat karena leakage, tetapi model tersebut tidak digunakan dalam pemilihan model utama.

8. Dokumentasi repository github

<https://github.com/FajarDwiharjo/UTS-Predictive-analytics-Fajar-Dwiharjo-24130500010>

